

Cultivating Machine Learning

Fuente complementaria para NotebookLM — vincula la teoría de *Practical Statistics for Data Scientists* (Bruce & Bruce) y *Statistical and Machine-Learning Data Mining* (Ratner) con un caso real de agricultura de precisión.

Este documento no reemplaza a los dos libros de referencia: los complementa. Los dos libros explican la teoría estadística y de machine learning en general; este documento explica **un caso concreto** — la predicción del estado de salud de un cultivo a partir de sensores IoT — y muestra, con números reales, cómo se ve cada concepto de esos libros aplicado a este dataset específico. Úsalo junto con los dos libros como fuente en NotebookLM: así los videos generados pueden explicar la teoría general y, en el mismo video, anclarla al ejemplo agrícola real.

El caso de estudio

Dataset: `Plant_health_data.csv` (Kaggle, autor gowthamduggirala). **1200 registros reales** (10 plantas × 120 lecturas cada una, tomadas cada 6 horas siempre a las mismas 4 horas del día: 4:00, 10:00, 16:00 y 22:00). **14 columnas:** un identificador de tiempo (Timestamp), un identificador de planta (Plant_ID), 10 sensores numéricos y la variable objetivo.

Sensores predictores (10): humedad de suelo (Soil_Moisture), temperatura ambiente (Ambient_Temperature), temperatura de suelo (Soil_Temperature), humedad relativa del aire (Humidity), intensidad lumínica (Light_Intensity), pH del suelo (Soil_pH), nitrógeno (Nitrogen_Level), fósforo (Phosphorus_Level), potasio (Potassium_Level) y una señal electroquímica (Electrochemical_Signal, proxy de conductividad eléctrica).

Variable objetivo (Plant_Health_Status): clasificación en 3 categorías — *Healthy* (saludable), *Moderate Stress* (estrés moderado) y *High Stress* (estrés alto). Es un problema de **clasificación**, no de regresión: el modelo predice una categoría, no un número continuo.

Objetivo del proyecto: replicar el flujo completo de un científico de datos — cargar el dato, limpiarlo, explorarlo, transformarlo, dividirlo, entrenar varios modelos y evaluarlos con rigor — usando este dataset agrícola real como hilo conductor.

1. El dato rectangular: la estructura de un dataset para Machine Learning

Qué dice la teoría

Antes de cualquier análisis, los datos se organizan en una tabla rectangular: cada fila es un registro (una observación) y cada columna es una variable (un feature o el target). Un modelo de ML necesita esta estructura para poder aprender: filas = ejemplos, columnas = características de cada ejemplo.

Cómo se ve en el caso Cultivating Machine Learning

El dataset tiene 1200 filas y 14 columnas. De esas 14, 10 son sensores numéricos que actúan como predictores (features), 2 son identificadores que no se usan como predictores (Timestamp, Plant_ID), 1 es una variable de comparación que tampoco se usa como predictor (Chlorophyll_Content) y 1 es la variable objetivo (Plant_Health_Status).

Concepto	Valor en este dataset
Registros (filas)	1200
Columnas totales	14
Sensores predictores	10
Clases del target	Healthy / Moderate Stress / High Stress

2. Medidas de tendencia central: media, mediana y moda

Qué dice la teoría

La media es el promedio de todos los valores; la mediana es el valor central cuando los datos se ordenan; la moda es el valor que más se repite. Las tres describen "dónde está el centro" de los datos, pero de formas distintas — la mediana, a diferencia de la media, no se deja arrastrar por valores extremos (outliers).

Cómo se ve en el caso Cultivating Machine Learning

Para los 10 sensores numéricos, la diferencia relativa entre media y mediana es pequeña en todos los casos (por debajo del 1.3%), lo que indica distribuciones bastante simétricas, sin outliers fuertes que desplacen la media.

Estadísticas descriptivas reales (describe()) de algunos sensores:

Sensor	Media	Mediana	Desv. estándar
Soil_Moisture	25.11	25.17	8.68
Light_Intensity	612.64	617.24	228.32
Soil_pH	6.52	6.54	0.58

Nitrogen_Level	30.11	30.14	11.51
----------------	-------	-------	-------

3. Limpieza de datos: elegir la imputación según el origen físico del sensor

Qué dice la teoría

Cuando faltan datos, la estrategia de imputación (cómo se rellenan los huecos) no debería ser una sola regla aplicada a ciegas a todas las variables: depende de cómo se comporta físicamente cada una. Un valor que sigue un ciclo temporal no se rellena igual que uno que cambia lentamente y sin patrón marcado.

Cómo se ve en el caso Cultivating Machine Learning

En esta copia del dataset no hay valores nulos (0 nulos detectados en los 10 sensores), pero la limpieza se deja lista igualmente, por si otra copia del CSV sí los trae. Se usan dos estrategias distintas según el sensor: (a) los sensores que siguen un ciclo — humedad de suelo, intensidad lumínica, temperatura ambiente y humedad relativa — se interpolan dentro de la serie temporal de cada planta (usando las lecturas cercanas en el tiempo de esa misma planta); (b) los sensores que cambian más lento y sin ciclo marcado — pH, nitrógeno, fósforo, potasio, temperatura de suelo y la señal electroquímica — se rellenan con la mediana global del sensor.

Estrategia	Sensores
Interpolación por planta (serie temporal)	Soil_Moisture, Light_Intensity, Ambient_Temperature, Humidity
Mediana global	Soil_Temperature, Soil_pH, Nitrogen_Level, Phosphorus_Level, Potassium_Level, Electrode

4. Medidas de dispersión: rango, varianza y desviación estándar

Qué dice la teoría

Estas medidas dicen qué tan dispersos están los datos alrededor del centro. El rango es la diferencia entre el valor máximo y el mínimo — simple, pero solo mira los dos extremos. La varianza es el promedio de las distancias al cuadrado respecto a la media — por elevarlas al cuadrado, queda en unidades al cuadrado, difíciles de interpretar directamente. La desviación estándar es la raíz cuadrada de la varianza — vuelve a las unidades originales del sensor y es, por eso, la medida de dispersión más interpretable de las tres.

Cómo se ve en el caso Cultivating Machine Learning

Tomando Soil_Moisture como ejemplo: sus valores van de un mínimo de 10.0 a un máximo de 40.0, un rango de aproximadamente 30 unidades. Su desviación estándar real es 8.68 (en las mismas unidades del sensor, %). Su varianza —el mismo cálculo antes de sacar la raíz— es por lo tanto $8.68^2 \approx 75.3$, en unidades al cuadrado, que ya no se leen directamente como "porcentaje de humedad".

Medida	Soil_Moisture
Mínimo	10.00
Máximo	39.99
Rango (máx – mín)	≈ 29.99
Desviación estándar	8.68
Varianza (8.68 ²)	≈ 75.3

5. Correlación de Pearson entre variables numéricas

Qué dice la teoría

El coeficiente de correlación de Pearson mide la fuerza y dirección de la asociación LINEAL entre dos variables continuas, en un rango de -1 a +1. Un valor cercano a 0 no implica ausencia total de relación — solo ausencia de relación lineal; podría haber una relación curva que Pearson no detecta.

Cómo se ve en el caso Cultivating Machine Learning

La matriz de correlación entre los 10 sensores muestra valores casi todos cercanos a 0 (por ejemplo, Soil_Moisture vs. Ambient_Temperature = -0.01; Light_Intensity vs. Soil_pH = 0.01). Esto sugiere que, en este dataset, los sensores son en su mayoría independientes entre sí — ninguno predice linealmente a otro con fuerza.

6. Comparar grupos con boxplots y el ANOVA F-test

Qué dice la teoría

Antes de entrenar cualquier modelo conviene preguntarse qué variables distinguen de verdad a los grupos que se quieren predecir. Un boxplot por clase deja ver a simple vista si una variable separa visualmente los grupos. El ANOVA F-test lo confirma con un número: compara el promedio de una variable ENTRE los grupos frente a qué tanto varía DENTRO de cada grupo — si F es alto y el p-valor es menor a 0.05, la diferencia entre grupos es real, no casualidad.

Cómo se ve en el caso Cultivating Machine Learning

Al aplicar el ANOVA F-test a los 10 sensores contra las 3 clases de Plant_Health_Status, solo dos resultan estadísticamente significativos: Soil_Moisture ($F \approx 899.26$, $p \approx 3.7 \times 10^{-23}$) y Nitrogen_Level ($F \approx 46.87$, $p \approx 2.5 \times 10^{-2}$). El resto de los sensores (Potassium_Level, Phosphorus_Level, Humidity, Soil_pH, Soil_Temperature, Light_Intensity, Electrochemical_Signal, Ambient_Temperature) tiene p-valores por encima de 0.05: no separan de forma confiable las 3 clases de salud.

Sensor	F	p-valor	¿Significativo?
--------	---	---------	-----------------

Soil_Moisture	899.26	$\approx 3.7e-239$	Sí
Nitrogen_Level	46.87	$\approx 2.5e-20$	Sí
Potassium_Level	3.00	≈ 0.050	No (borde)
Resto de sensores	< 3	> 0.05	No

7. Asimetría (skew) y la escalera de potencias de Tukey

Qué dice la teoría

Cuando una variable tiene la mayoría de sus valores parecidos y unos pocos valores muy altos (o muy bajos), esa forma se llama sesgo o asimetría (skew): si se grafica, se ve estirada hacia un lado. John Tukey propuso la "escalera de potencias": si una variable tiene cola larga, se aplica una transformación (como el logaritmo) para "enderezar" su relación con otras variables. Se usa $\log_{10}(x + 1)$ en vez de $\log_{10}(x)$ para evitar el problema de $\log(0)$.

Cómo se ve en el caso Cultivating Machine Learning

En este dataset, el sesgo (skew) de los 10 sensores es cercano a 0 en todos los casos (el más alto, en valor absoluto, es Soil_pH con -0.085). Al aplicar $\log_{10}(x+1)$ sobre Light_Intensity y comparar su correlación con Chlorophyll_Content antes y después, la correlación casi no cambia — un resultado honesto: no toda variable necesita transformarse, y en este caso los datos ya vienen razonablemente simétricos.

8. Partición de datos y estandarización (Z-score)

Qué dice la teoría

Antes de entrenar un modelo hay que separar los datos en un conjunto de entrenamiento y uno de prueba, para saber si el modelo de verdad aprendió o solo memorizó. La partición estratificada conserva la proporción de cada clase en ambos conjuntos — importante cuando una clase es minoritaria. Además, hay que estandarizar los sensores con el método Z-score ($z = (x - \text{media}) / \text{desviación estándar}$), para que ningún sensor domine solo por tener números más grandes en su escala original.

Cómo se ve en el caso Cultivating Machine Learning

La partición usa 80% para entrenamiento y 20% para prueba, de forma estratificada (960 registros de entrenamiento, 240 de prueba). El escalador (StandardScaler) se ajusta SOLO con los datos de entrenamiento, para no filtrarle al modelo información del conjunto de prueba (fuga de datos).

Conjunto	Registros
Entrenamiento (80%)	960

Prueba (20%)	240
--------------	-----

9. Regresión logística para clasificación

Qué dice la teoría

La regresión logística es un modelo paramétrico que estima la probabilidad de pertenecer a una clase transformando una combinación lineal de las variables mediante la función logit. Se ajusta por máxima verosimilitud (no por mínimos cuadrados) y traza una frontera de decisión lineal entre clases — es interpretable, pero limitada cuando la relación real entre variables y clases no es lineal.

Cómo se ve en el caso Cultivating Machine Learning

Entrenada sobre los 10 sensores estandarizados, la regresión logística obtiene un accuracy de 0.7375 y un F1-macro de 0.7336 sobre el conjunto de prueba — el resultado más bajo de los 4 modelos comparados en este proyecto, consistente con que la relación real entre los sensores y el estado de salud no es puramente lineal.

Métrica	Valor
Accuracy	0.7375
F1-macro	0.7336

10. Árboles de decisión (CART)

Qué dice la teoría

Un árbol de decisión (CART, Breiman 1984) es un modelo no paramétrico que parte recursivamente el espacio de variables en reglas jerárquicas del tipo "¿el sensor X es menor que un umbral?", hasta llegar a regiones cada vez más puras. En cada nodo, el árbol elige la variable y el punto de corte que más reduce la impureza (medida con el índice de Gini). Limitar la profundidad máxima (max_depth) evita que el árbol memorice el ruido del entrenamiento (sobreajuste).

Cómo se ve en el caso Cultivating Machine Learning

Con max_depth=4, el árbol CART alcanza accuracy = 1.0000 y F1-macro = 1.0000 sobre el conjunto de prueba — un ajuste perfecto. Esto vale la pena mirarlo con sospecha, no solo con satisfacción: un resultado perfecto puede indicar que el dataset se generó con reglas o umbrales simples, no necesariamente que el problema sea trivial de resolver en el mundo real.

Métrica	Valor
Accuracy	1.0000
F1-macro	1.0000

11. Ensamblados de árboles: Bagging y Random Forest

Qué dice la teoría

Un ensamble combina muchos modelos en vez de confiar en uno solo. El Bagging (Bootstrap Aggregating) entrena muchos árboles en paralelo, cada uno sobre una muestra bootstrap (con reemplazo) del conjunto de entrenamiento, y combina sus predicciones por voto mayoritario (la clase que más árboles eligieron) — no promediando números, porque esto es clasificación, no regresión. Random Forest añade aleatoriedad extra: en cada partición solo se evalúa un subconjunto aleatorio de variables, lo que descorrelaciona los árboles y reduce la varianza del conjunto.

Cómo se ve en el caso Cultivating Machine Learning

Con 200 árboles, Random Forest alcanza $\text{accuracy} = 1.0000$ y $\text{F1-macro} = 1.0000$. Su ranking de importancia de variables (cuánto reduce cada sensor la impureza promedio) confirma lo que ya había mostrado el ANOVA de la sección 6: Soil_Moisture domina con 67.37% de la importancia total, seguido de Nitrogen_Level con 18.79% — el resto de los sensores aporta menos del 3% cada uno.

Sensor	Importancia
Soil_Moisture	67.37%
Nitrogen_Level	18.79%
Soil_pH	2.12%
Resto (7 sensores)	< 2% cada uno

12. Ensamblados de árboles: Boosting y XGBoost

Qué dice la teoría

A diferencia del bagging (árboles en paralelo), el boosting entrena árboles de forma secuencial: cada árbol nuevo corrige el error residual que dejó el conjunto de árboles anteriores, mediante descenso de gradiente. El `learning_rate` controla cuánto corrige cada nuevo árbol — valores bajos generalizan mejor, pero requieren más árboles para converger.

Cómo se ve en el caso Cultivating Machine Learning

XGBoost, con 200 árboles, `learning_rate=0.05` y `max_depth=3`, alcanza $\text{accuracy} = 0.9958$ y $\text{F1-macro} = 0.9951$ — un resultado muy alto, pero no perfecto como el de CART o Random Forest, lo que lo hace, en cierto sentido, más creíble como reflejo de la dificultad real del problema.

Métrica	Valor
Accuracy	0.9958
F1-macro	0.9951

13. Validación cruzada e importancia de variables

Qué dice la teoría

Un solo reparto entrenamiento/prueba puede ser optimista o pesimista por azar. La validación cruzada de k folds repite el entrenamiento k veces, cada vez dejando una porción distinta de los datos como prueba, y compara los k resultados — si son parecidos entre sí, el modelo es estable; si varían mucho, el resultado depende demasiado de cómo se hizo la partición.

Cómo se ve en el caso Cultivating Machine Learning

Sobre Random Forest, una validación cruzada de 5 folds da los siguientes F1-macro: 0.9954, 0.9906, 0.9906, 1.0000 y 1.0000 — con un promedio de 0.9953 y una desviación estándar de apenas 0.0042. Esta baja variación confirma que el resultado casi perfecto de Random Forest no depende de un reparto afortunado de los datos.

Fold	F1-macro
1	0.9954
2	0.9906
3	0.9906
4	1.0000
5	1.0000
Promedio ± desv. estándar	0.9953 ± 0.0042

14. Métricas de evaluación: accuracy, precisión, recall y F1-macro

Qué dice la teoría

El accuracy es la proporción total de predicciones correctas — pero puede ser engañoso si las clases están desbalanceadas. La precisión responde "de lo que el modelo predijo como una clase, cuánto acertó"; el recall responde "de lo que realmente era esa clase, cuánto detectó el modelo". El F1-macro es la media armónica de precisión y recall, promediada con el mismo peso para cada clase — por eso es la métrica preferida cuando una clase (como "High Stress") es minoritaria: un accuracy alto podría estar ocultando que el modelo falla justo en la clase más importante de detectar.

Cómo se ve en el caso Cultivating Machine Learning

La matriz de confusión del mejor modelo (Árbol CART) sobre las 240 muestras de prueba es perfectamente diagonal: 60 aciertos en Healthy, 100 en High Stress y 80 en Moderate Stress, sin ningún error fuera de la diagonal — de ahí su precisión, recall y F1 de 1.00 en las tres clases por igual.

Clase	Precisión	Recall	F1-score	Soporte
Healthy	1.00	1.00	1.00	60

High Stress	1.00	1.00	1.00	100
Moderate Stress	1.00	1.00	1.00	80

15. Elegir el mejor modelo: comparación final y sospecha de resultados perfectos

Qué dice la teoría

El último paso de un proyecto de clasificación es comparar todos los modelos entrenados bajo las mismas métricas y, con eso, elegir uno — pero un buen científico de datos también cuestiona resultados demasiado buenos para ser ciertos, en vez de solo celebrarlos.

Cómo se ve en el caso Cultivating Machine Learning

La tabla comparativa final de los 4 modelos entrenados en este proyecto es la siguiente. El modelo recomendado por F1-macro es el Árbol CART. Sin embargo, que 3 de los 4 modelos lleguen a un ajuste perfecto (1.00) es motivo de sospecha, no solo de éxito: vale la pena revisar si el dataset se generó con umbrales simples y bien separados entre clases, algo poco frecuente en datos de sensores agrícolas reales.

Modelo	Accuracy	F1-macro
Regresión Logística	0.738	0.734
Árbol CART	1.000	1.000
Random Forest	1.000	1.000
XGBoost	0.996	0.995